

Görsel Crowding Etkisinin Farklı Mimari Ailelerinde Karşılaştırmalı Analizi

ResNet · ViT · Swin · KAN | Open Images v7 + SAM2

1. Giriş ve Motivasyon

Görsel crowding, hedef nesnenin algılanmasının etrafındaki flanker nesneler tarafından baskılanması olgusudur. Bu çalışmada üç farklı mimari ailesinden (CNN, Transformer, KAN) 10 modelin crowding dayanıklılığı karşılaştırılmıştır. Transformer ailesi iki alt-tipi kapsayacak şekilde genişletilmiştir: global attention (ViT-S/16, ViT-B/16) ve hiyerarşik, kaydırmalı pencere (shifted-window) attention (Swin-T, Swin-S). Bu ayrım, crowding'in hedefin etrafındaki yerel özellik havuzlamasının flanker'lar tarafından bozulmasıyla ilgili olması nedeniyle önemlidir: Swin'in pencereli attention'ı CNN'in yerel/hiyerarşik işleme yapısına ViT'ten daha yakındır.

1.1. Temel Kavramlar

Crowding Index (CI) = (Acc_isolation – Acc_crowding) / Acc_isolation

CI [0,1] arasında değer alır. 0: dayanıklı, 1: çok duyarlı. Negatif CI: flanker performansı artırıyor.

Top-1 Accuracy: En yüksek olasılıklı tahmin doğru mu?

Top-5 Accuracy: 30 sınıf arasından en yüksek 5 tahmin içinde gerçek sınıf var mı?

Bouma Yasası: Kritik spacing ~ nesne boyutunun 0.4-0.5 katı. Bu değerin üzerinde crowding azalır.

2. Yöntem

2.1. Veri Seti

Kaynak: Open Images v7 | Maske: SAM2 | 30 sınıf | Sınıf başına maks. 500 örnek

Split: %70 train / %15 val / %15 test — instance bazlı strict split

Sınıflar: Car, Person, Bottle, Dog, Airplane, Bird, Motorcycle, Horse, Cat, Book, Truck, Bus, Laptop, Cake, Elephant, Backpack, Sheep, Couch, Pizza, Toilet, Clock,

Giraffe, Zebra, Bear, Tiger, Traffic light, Stop sign, Fire hydrant, Skateboard, Suitcase

2.2. Görsel Hazırlama

Canvas: 224x224 piksel, siyah arka plan | Nesne: uzun kenar 80px, aspect ratio korunur

2.3. Crowding Koşulları

Flanker: Sol ve sağda simetrik, her iki tarafta aynı instance | Spacing: Center-to-center, $1^\circ=40\text{px}$

Spacing (°)	Piksel (px)
2.0°	80 px
2.3°	92 px
2.5°	100 px
2.7°	108 px
3.0°	120 px

Flanker tipleri: Congruent (aynı sınıf, farklı instance) | Incongruent (farklı sınıf)

2.4. Eğitim — LP-FT

LP: 15 epoch, backbone dondurulur, $\text{lr}=0.001$

FT: 30 epoch, tüm model açılır, $\text{lr}=0.0001 \rightarrow 0.000001$ (cosine decay)

AdamW | weight_decay=0.0001 | gradient_clip=1.0 | label_smoothing=0.1 | early_stop=7

Pretrained: ImageNet-1K (tüm modeller, KAN dahil). Önceki turda KAN modelleri (VGG KAGN-BN, VGG KAGN) pretrained ağırlıklar yüklenemediğinden scratch başlıyordu. Bu sorun çözüldü: HuggingFace brivangl/vgg_kagn11_v2, vgg_kagn11_v4, vgg_kagn_bn11sa_v4 repo'larının config.json'larından birebir kopyalanan mimari kwargs'larıyla model kuruluyor, model.safetensors yükleniyor; load_state_dict tam eşleşmezse (missing/unexpected key) artık sessizce scratch'e düşmek yerine hata fırlatılıyor.

3. Model Profilleri

Model	Mimari	Parametre	Disk Boyutu	FLOPs	GPU Latency
ResNet-34	CNN	21.3M	81.3 MB	3.68 G	1.375 ms
ResNet-50	CNN	23.6M	90.1 MB	4.14 G	1.569 ms
ResNet-101	CNN	42.6M	162.8 MB	7.88 G	2.988 ms
ViT-S/16	Transformer (global)	21.7M	82.7 MB	4.25 G	1.794 ms
ViT-B/16	Transformer (global)	85.8M	327.4 MB	16.87 G	3.593 ms
Swin-T	Transformer (windowed)	27.5M	106.1 MB	4.51 G	11.648 ms
Swin-S	Transformer	48.9M	187.9 MB	8.77 G	23.750 ms

	(windowed)				
VGG KAGN-11v2	KAN	24.4M	93.1 MB	—	8.663 ms
VGG KAGN-11v4	KAN	40.9M	156.1 MB	—	8.983 ms
VGG KAGN-BN-SA-11v4	KAN	12.0M	46.0 MB	—	10.383 ms

FLOPs: KAN modelleri için fvcare, özel Kolmogorov-Arnold konvolüsyon operasyonlarını desteklemediğinden hesaplanamamıştır (—).

Latency: tek görsel inference süresi, NVIDIA A100-SXM4-40GB (Colab).

4. Sonuçlar

4.1. Ana Performans Metrikleri

Model	Iso. Top-1	Iso. Top-5	Crowding Acc	CI (yüksek=kötü)	ECE (düşük=iyi)
ResNet-34	0.7988	0.9505	0.6332	0.2073	0.1423
ResNet-50	0.8231	0.9505	0.6146	0.2533	0.2058
ResNet-101	0.8347	0.9514	0.5970	0.2847	0.2566
ViT-S/16	0.8021	0.9407	0.5949	0.2583	0.2226
ViT-B/16	0.7535	0.9332	0.5278	0.2995	0.1367
Swin-T	0.8557	0.9594	0.6855	0.1990	0.0919
Swin-S	0.8791	0.9711	0.6749	0.2323	0.1407
VGG KAGN-11v2	0.7740	0.9613	0.5644	0.2709	0.0262
VGG KAGN-11v4	0.7684	0.9589	0.5893	0.2331	0.0515
VGG KAGN-BN-SA-11v4	0.7558	0.9304	0.5014	0.3366	0.0670

4.2. Spacing Bazlı Accuracy ve CI

Model	2.0 acc	2.0 CI	2.3 acc	2.3 CI	2.5 acc	2.5 CI	2.7 acc	2.7 CI	3.0 acc	3.0 CI
ResNet-34	0.5474	0.3147	0.5815	0.2720	0.6171	0.2275	0.6714	0.1595	0.7485	0.0630
ResNet-50	0.5189	0.3696	0.5407	0.3431	0.5781	0.2977	0.6664	0.1904	0.7687	0.0661
ResNet-101	0.4813	0.4234	0.5196	0.3775	0.5624	0.3262	0.6581	0.2116	0.7637	0.0851
ViT-S/16	0.5609	0.3007	0.5622	0.2991	0.5797	0.2773	0.6037	0.2474	0.6680	0.1672
ViT-B/16	0.4992	0.3375	0.5041	0.3310	0.5203	0.3095	0.5337	0.2917	0.5817	0.2280
Swin-T	0.6508	0.2395	0.6566	0.2327	0.6752	0.2109	0.6945	0.1884	0.7503	0.1232
Swin-S	0.6115	0.3044	0.6351	0.2776	0.6649	0.2437	0.6985	0.2054	0.7644	0.1305
VGG KAGN	0.5033	0.3497	0.5293	0.3161	0.5505	0.2888	0.5835	0.2461	0.6552	0.1535

-11v2										
VGG	0.528	0.312	0.554	0.278	0.579	0.245	0.610	0.205	0.673	0.123
KAGN	6	1	1	9	9	3	2	9	6	4
-11v4										
VGG	0.435	0.424	0.467	0.381	0.496	0.343	0.534	0.293	0.573	0.241
KAGN	3	1	6	3	3	3	2	2	6	1
-BN-										
SA-										
-11v4										

4.3. Flanker Tipine Göre Accuracy ve CI

Model	Congruent Acc	Congruent CI	Incongruent Acc	Incongruent CI
ResNet-34	0.9040	-0.1317	0.4932	0.3826
ResNet-50	0.9108	-0.1065	0.4615	0.4393
ResNet-101	0.9145	-0.0956	0.4301	0.4847
ViT-S/16	0.9018	-0.1243	0.4366	0.4557
ViT-B/16	0.8386	-0.1129	0.3775	0.4990
Swin-T	0.9348	-0.0924	0.5582	0.3477
Swin-S	0.9622	-0.0945	0.5272	0.4003
VGG KAGN-11v2	0.8709	-0.1252	0.4122	0.4674
VGG KAGN-11v4	0.8838	-0.1502	0.4473	0.4179
VGG KAGN-BN-SA-11v4	0.7747	-0.0250	0.3615	0.5217

Not: "external" flanker koşulu bu raporda değerlendirilmemiştir — bu koşul mevcut kompozit üretim pipeline'ında henüz üretilmemektedir; ayrı bir çalışma gerektirir.

5. Tartışma

5.1. Mimari Karşılaştırması

CNN: Derinlik arttıkça hem isolation accuracy hem CI artıyor. ResNet-34→50→101: iso 0.799→0.823→0.835, CI 0.207→0.253→0.285. Daha derin CNN'ler crowding'e daha duyarlı.

Transformer — global attention (ViT): ViT-B/16, ViT-S/16'dan daha düşük isolation accuracy'ye (0.754 vs 0.802) rağmen daha yüksek CI gösteriyor (0.300 vs 0.258). Dahası, ViT-B/16'nın 0.7535'lik isolation accuracy'si 10 modelin en düşüğü — artık pretrained olan KAN modellerinin bile altında. Global attention mekanizmasının, kapasite arttığında bu veri rejiminde hem genelleme hem de flanker'a karşı dayanıklılık açısından dezavantaja dönüştüğünü gösteriyor.

Transformer — windowed attention (Swin): Swin-T, 10 modelin tamamı arasında en düşük CI'ye (0.1990) ve ikinci en yüksek isolation accuracy'ye (0.8557) sahip — yani hem en isabetli hem en dayanıklı model. Swin-S ise en yüksek isolation accuracy'yi (0.8791) elde ediyor ama CI'si Swin-T'ye göre kötüleşiyor (0.2323) — CNN ve ViT'te gözlenen "kapasite arttıkça CI kötüleşir" örüntüsü Swin ailesinde de tekrarlanıyor. Buna rağmen Swin-S mutlak CI değerinde tüm ResNet ve ViT modellerinden daha dayanıklı kalıyor. Bu sonuç, yerel pencereli attention'ın

flanker etkisini, her pencerenin sınırlı bir bölgeyle sınırlı kalması sayesinde global attention'a göre daha iyi izole ettiğini düşündürüyor.

KAN: Artık pretrained ağırlıklarla adil bir karşılaştırma mümkün (isolation accuracy 0.756-0.774, CNN/ViT/Swin'e yakın). Alt-ailede de aynı kapasite-CI örüntüsü gözleniyor: VGG KAGN-11v4 (40.9M param, CI=0.2331) < VGG KAGN-11v2 (24.4M param, CI=0.2709) < VGG KAGN-BN-SA-11v4 (12.0M param, CI=0.3366 — en yüksek CI). BN-SA-11v4'ün en az parametrelili KAN olmasına rağmen en kırılabilir model olması dikkat çekici: eklenen self-attention ve BatchNorm bileşenlerinin — tıpkı ViT'teki global attention gibi — ham parametre sayısından bağımsız olarak crowding dayanıklılığını düşürdüğünü gösteriyor.

Genel bulgu (4 alt-aile): "Kapasite/karmaşıklık arttıkça CI kötüleşir" örüntüsü artık CNN (34→50→101), ViT (S→B), Swin (T→S) ve KAN (11v4→11v2→BN-SA) alt-ailelerinin hepsinde tutarlı şekilde gözleniyor. En dayanıklı model: Swin-T (CI=0.1990). En kırılabilir model: VGG KAGN-BN-SA-11v4 (CI=0.3366).

5.2. Flanker Tipi

Congruent: Tüm modellerde negatif CI — aynı sınıf flanker performansı artırıyor. En belirgin VGG KAGN-11v4'te (CI=-0.1502); en zayıf VGG KAGN-BN-SA-11v4'te (CI=-0.0250) — bu model congruent flanker'dan bile diğer modeller kadar faydalanamıyor.

Incongruent: Anlamlı CI değerleri (0.35-0.52). En dayanıklı model burada da Swin-T (CI=0.3477); en kırılabilir yine VGG KAGN-BN-SA-11v4 (CI=0.5217). Farklı sınıf flanker, hedef nesnenin özellik temsilini baskılıyor.

5.3. Spacing

Tüm modellerde spacing arttıkça CI düşüyor (Bouma Yasası ile uyumlu). ViT-B/16 spacing artışına en az duyarlı model kalmaya devam ediyor (2.0°→3.0° arası CI değişimi yalnızca 0.110); en duyarlı (en hızlı toparlanan) model ResNet-34 (0.3147→0.0630, 0.252 azalma).

5.4. Kalibrasyon

En iyi kalibre edilen üç model de KAN ailesinden: VGG KAGN-11v2 (ECE=0.0262), VGG KAGN-11v4 (0.0515), VGG KAGN-BN-SA-11v4 (0.0670). Bu üçünün hemen ardından Swin-T geliyor (0.0919) — KAN dışındaki en iyi kalibre edilen model. En kötü kalibre model ResNet-101 (ECE=0.2566). KAN'ın düşük isolation accuracy'sine rağmen (CNN/ViT/Swin'in altında) belirgin şekilde daha iyi kalibre olması, mimariye özgü bir özellik olarak öne çıkıyor.

6. Sınırlılıklar ve Gelecek Çalışmalar

- Çözüldü: KAN modelleri artık ImageNet-1K pretrained ağırlıklarla başlıyor; CNN/ViT/Swin ile adil karşılaştırma sağlandı.

- KAN modellerinin FLOPs değeri hesaplanamıyor — fvcare özel Kolmogorov-Arnold konvolüsyon operasyonlarını desteklemiyor; manuel FLOP hesaplaması gerekebilir.
- Dış nesne (external flanker) koşulu bu turda değerlendirilmedi — mevcut pipeline bu koşulu üretmiyor, ayrı bir veri üretim + değerlendirme adımı gerektiriyor.
- Gelecek: Grad-CAM analizi, insan psikofiziği karşılaştırması, dikey eksen crowding, external flanker koşulunun eklenmesi, daha büyük KAN varyantları (width_scale artırılarak).

7. Referanslar

Bouma (1970). Interaction effects in parafoveal letter recognition. *Nature*.

Volokitin et al. (2017). Do deep neural networks suffer from crowding? *NeurIPS*.

Lonnqvist et al. (2020). Crowding in humans is unlike that in CNNs. *Neuropsychologia*.

Kumar et al. (2022). Fine-tuning can distort pretrained features. *ICLR*.

Drokin (2024). Kolmogorov-Arnold Convolutions. *arXiv:2407.01092*.

Kirillov et al. (2023). Segment Anything. *ICCV*.

Dosovitskiy et al. (2021). An Image is Worth 16x16 Words. *ICLR*.

Liu et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *ICCV*.

He et al. (2016). Deep Residual Learning for Image Recognition. *CVPR*.